Sistem za automatsko generisanje opisa za slike

Nebojša Vuga R2 23/2024, Bogdan Janošević R2 43/2024

1. Definicija problema

Problem koji ovaj projekat rešava je automatsko generisanje tekstualnih opisa za slike. Cilj projekta je razvoj sistema koji će, koristeći tehnike veštačke inteligencije, analizirati vizuelne informacije na slici i automatski generisati opis koji odgovara toj slici.

2. Motivacija

Jedna od ključnih primena ovog sistema je u poboljšanju pristupačnosti za osobe sa oštećenjem vida. Automatski generisani opisi slika omogućavaju slepim i slabovidim osobama bolji uvid u sadržaj interneta i digitalnih medija, pružajući im iskustvo slično onom koje imaju osobe bez oštećenja vida. Dodatno, ovaj sistem može biti koristan za velike baze slika, kao što su arhive i društvene mreže. Tu se opisivanje vizuelnog sadržaja može automatizovati što omogućava lakše pretraživanje i organizaciju.

3. Relevantna literature

3.1 Image Captioning using Artificial Intelligence

[1] *SINGH, Yajush Pratap, et al. Image captioning using artificial intelligence. In: Journal of Physics: Conference Series. IOP Publishing, 2021. p. 012048.*

https://iopscience.iop.org/article/10.1088/1742-6596/1854/1/012048/pdf

1. **Zadatak** - Rad se bavi razvojem modela za generisanje opisa slika koristeći duboke neuronske mreže. Cilj je automatski generisati prirodne opise slika koje odgovaraju sadržaju slike.

2. **Metodologija** – Koristi kombinaciju konvolutivnih neuronskih mreža (***CNN***) za ekstrakciju karakteristika iz slika i rekurentnih neuronskih mreža (***RNN***), tj ***LSTM*** *(Long Short-Term Memory)* za generisanje tekstualnih opisa.

3. **Skup podataka –** Korišćen je Flickr8k dataset koji ima oko 8 hiljada slika i 5 opisa po slici. Atributi skupa podataka su slike, a ciljno obeležje je opis te slike. Link ka datasetu je: https://www.kaggle.com/datasets/adityajn105/flickr8k

4. **Evaluacija -** Korišćena je *BLEU* metrika za evaluaciju generisanih opisa. Dataset je podeljen na trening i test skupove pri čemu je model treniran na jednom delu skupa podataka, a testiran na drugom.

5. **Rezultati** – Pokazano je da je kombinacija *CNN* i *LSTM* modela efikasna u generisanju opisa. Generisani opisi su bili od 80% do 90% tačni.

6. **Zaključak** – Ovaj rad je relevantan za naš projekat jer koristi *CNN* i *LSTM* arhitekturu, što je jedna od metodologija koju planiramo primeniti. Takođe ćemo kao jednu od mera evaluacija koristiti *BLEU* metriku koju je ovaj rad koristio. Naš rad će se razlikovati po tome što ćemo imati veći dataset, odnosno Flickr30k, kao i više arhitektura i metoda evaluacije.

3.2 The Unreasonable Effectiveness of CLIP Features for Image Captioning: An Experimental Analysis

[2] *BARRACO, Manuele, et al. The unreasonable effectiveness of CLIP features for image captioning: an experimental analysis. In: proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022. p. 4662-4670.*

https://openaccess.thecvf.com/content/CVPR2022W/MULA/papers/Barraco_The_Unreasonable_Effectiveness_of_CLIP_Features_for_Image_Captioning_An_CVPRW_2022_paper.pdf

1. Zadatak – *CLIP* je model koji je prethodno istreniran i on kombinuje slike i tekst. Omogućuje generisanje opisa slika bez specifičnog *fine-tuning*-a. U ovom radu se istražuje da li *CLIP* može da bude efikasan u zadatku generisanja opisa slika u odnosu na druge metodologije koje se koriste u tom kontekstu. Među drugim metodologijama su detektori objekata i slične strategije za prepoznavanje slike i generisanje opisa.

2. **Metodologija –** Rad koristi različite varijante CLIP modela, među kojima su ResNet i ViT arhitekture. Oni služe kao vizuelni enkoderi za zadatak generisanja opisa slika. Model se kombinuje sa encoder-decoder sistemom, gde je tekstualni deo generisan pomoću prirodno jezičkog modela. Istraživanje se fokusira na to kako CLIP može da bude korišćen u zero-shot režimu, odnosno bez dodatnog treniranja na specifičnim skupovima podataka za zadatak generisanja opisa slika.

3. **Skup podataka –** Korišćen je COCO dataset. On sadrži slike sa opisima koje su napisali ljudi. Takođe, koristi i dataset kao što je VizWiz, TextCaps i CC3M kako bi testirao model na različitim skupom podataka.

Linkovi su:

Coco - https://cocodataset.org/#home

VizWiz - https://paperswithcode.com/dataset/vizwiz

TextCaps - https://textvqa.org/textcaps/

CC3M - https://github.com/rom1504/img2dataset/blob/main/dataset_examples/cc3m.md

4. Evaluacija - Za evaluaciju su korišćene sledeće metrike: CIDEr, BLEU, ROUGE i METEOR. Skup je podeljen na trening i test, ali su rezultati prikazani u zero-shot režimu.

5. Rezultati – CLIP model sa ResNet i ViT arhitekturom je postigao bolje rezultate u odnosu na druge pristupe koji koriste detektore objekata ili druge metode zasnovane na prepoznavanju slika i teksta. Na osnovu ovih rezultata se zaključuje da je CLIP model vrlo efikasan za generisanje opisa slika, čak i bez fine-tuninga modela. CLIP sa ViT arhitekturom se pokazao superiornijim nego sa ResNet. Primera radi, za CIDEr metriku je imao 2.3 više poena sa ViT nego sa ResNet, odnosno sa ViT je imao 139.4, a sa ResNet 137.1.

6. **Zaključak –** Ovaj rad je relevantan jer koristi različite CLIP arhitekture kao što su ResNet i ViT. U našem radu ćemo pored CNN i RNN arhitekture raditi sa CLIP arhitekturama navedenim u ovom radu. Takođe, pored BLEU metrike ćemo iz ovog rada izvući ROUGE i METEOR metriku. Razlika ovog i našeg rada je što ćemo i fine tune-ovati naš model kako bi izvukli što bolje rezultate. Pored fine tuning-a podataka, koristićemo različit dataset, odnosno Flickr30k.

3.3 ClipCap: CLIP Prefix for Image Captioning

[3] *MOKADY, Ron; HERTZ, Amir; BERMANO, Amit H. Clipcap: Clip prefix for image captioning. arXiv preprint arXiv:2111.09734, 2021.*

https://arxiv.org/pdf/2111.09734

1. **Zadatak** – Razviti metodu za generisanje opisa slika koristeći pretrenirane modele: CLIP i GPT-2, sa minimalnim dodatnim treniranjem. Rad koristi jednostavne modele koji se brzo treniraju. Cilj je da se postigne visoka tačnost uz malu potrošnju resursa i vremena.

2. **Metodologija** – Korišćen je pristup zasnovan na pretreniranim modelima. Ti modeli su CLIP za vizuelnu semantiku i GPT-2 za generisanje teksta. Rad koristi mapiranje između slike i jezika kroz minimalnu mrežu za mapiranje. Ta mreža je obučena za specifičan skup podataka, dok su pretrenirani modeli (CLIP i GPT-2) korišćeni bez dodatnog treniranja semantičkih entiteta.

3. **Skup podataka –** U radu su korišćeni COCO, Conceptual Captions i nocaps skupovi podataka. Oni sadrže slike sa pratećim opisima. Conceptual Captions sadrži 12 miliona slika sa opisima.

Linkovi za datasetove:

Conceptual captions - https://ai.google.com/research/ConceptualCaptions/download

Nocaps - https://nocaps.org/download

4. **Evaluacija –** Evaluacija je izvršena korišćenjem sledećih metrika: BLEU, CIDEr, ROUGE-L, SPICE i METEOR. Dobijeni rezultati se upoređuju sa drugim metodama kao što su VLP i Oscar.

5. **Rezultati –** Iz rezultata se zaključuje da metod zasnovan na pretreniranim modelima (CLIP i GPT-2) efikasno generiše opise slika bez potrebe za velikim brojem dodatnih parametara ili pretreniranja. Za kompleksnije skupove kao što je Conceptual Captions, fine-tuning jezika daje bolje rezultate. Za jednostavnije skupove, odnosno COCO, bez fine-tuninga rezultati mogu biti bolji. Metod se takođe pokazao dobrim na novim, neviđenim slikama.

6. **Zaključak –** Iz ovog rada ćemo izvući još jedan način za generisanje opisa, odnosno CLIP za vizuelnu semantiku, a GPT-2 za generisanje teksta. Razlika je u dataset-u koji će biti korišćen kako za trening, tako i za testiranje podataka.

4. Skup podataka

Skup podataka koji ćemo koristiti za projekat smo preuzeli sa sledećeg linka: https://paperswithcode.com/dataset/flickr30k. Ovaj dataset predstavlja Flickr-ovih 30 hiljada slika gde svaka slika sadrži po 5 različitih opisa te slike. Ti opisi su dati u vidu jedne rečenice koja govori šta se nalazi na slici. Na slici 1 se nalazi jedna od slika iz dataseta. Na slici 2 se nalaze opisi za datu sliku.

Slika 1 – Primer slike iz dataseta

image_name| comment_number| comment
1000092795.jpg| 0| Two young guys with shaggy hair look at their hands while hanging out in the yard .
1000092795.jpg| 1| Two young men are standing in a garden .
1000092795.jpg| 2| Two men in green shirts are standing in a yard .
1000092795.jpg| 3| A man in a blue shirt standing in a garden .
1000092795.jpg| 4| Two friends enjoy time spent together .

Slika 2 – Primer opisa slike iz dataseta

Ciljno obeležje predstavlja tekstualni opis slike. Njegov sadržaj predstavlja jednu rečenicu koja je dužine od oko 10-20 reči. Atribut skupa podataka je sama slika. U datom skupu, minimalan broj reči je 2, dok je maksimalan broj reči oko 70.

5. Metodologija

Sve slike iz skupa podataka biće skalirane na standardne dimenzije (224x224). Takođe, pikseli će se normalizovati u vrednosti od 0 do 1. Opisi pratećih tekstova biće tokenizovani uz dodavanje specijalnih tokena: Start i End.

U ovom projektu koristićemo različite metode za generisanje opisa slike. Te metode su:

- CNN i RNN (LSTM) - Koristiće se konvolucione neuronske mreže (CNN) za ekstrakciju vizuelnih karakteristika sa slike. Ekstrahovane karakteristike se zatim prosleđuju sekvencijalnom modelu, poput Long Short-Term Memory (LSTM), koji generiše tekstualni opis slike.
- Clip based arhitekture (ResNet i ViT) - Ovi modeli su pretrenirani na velikim skupovima slika i odgovarajućih tekstova, čime pružaju izuzetno precizne reprezentacije. Planirano je prilagođavanje Clip modela za specifične domene kroz *fine-tuning*.
- Clip + GPT-2 - U ovom pristupu, vizuelne karakteristike generisane Clip modelom služe kao ulaz za jezički model GPT-2, koji na osnovu tih karakteristika generiše detaljan opis slike.

6. Metod evaluacije

Za evaluaciju predikcije koristićemo:

- *BLEU (Bilingual Evaluation Understudy)* [link]
- *ROUGE* (*Recall-Oriented Understudy for Gisting Evaluation*) [link].
- *METEOR (Metric for Evaluation of Translation with Explicit Ordering)* [link]

BLEU evaluacija je dobra za strogo ocenjivanje tačnosti (*precision*) n-grama. Ne uzima u obzir red reči, sinonime ili značenje. Njegova mana je što ignoriše semantičku sličnost i bogatstvo jezika. Na našem projektu je koristan za baznu evaluaciju. S njim možemo videti koliko precizno sistem generiše opis na osnovu referentnog opisa. *ROUGE* je dobar za evaluaciju pokrivenosti ključnih reči i fraza iz referentnih opisa (*recall*). Takođe je dobar za proveru da li opis obuhvata sve bitne elemente. On bolje odražava pokrivenost nego *BLEU.* Mana *ROUGE*-a je što ne obrađuje sinonime ili semantičke ekvivalente. Sa njim možemo videti da li generisan opis uzima ključne informacije sa slike, čak iako nisu precizni n-grami. *METEOR* je najbolji za evaluaciju semantičke sličnosti i jezičke raznovrsnosti. On kombinuje precission i recall uz harmonijsku sredinu. Uključuje sinonime što daje mnogo bolji rezultat. Pored tačnosti, ocenjuje i jezičku prirodu. Mana je što je sporiji od *BLEU i ROUGE* i zahteva kvalitetnije referentne opise. Nama je koristan za ocenu prirodnosti opisa.

Odnos trening, validacionog i test skupa će biti 70:20:10 ili 60:30:10. Tačan odnos ćemo odrediti kada budemo trenirali modele. Na kraju ćemo porediti rezultate svih modela koje smo koristili, kako bi ustanovili koji model daje najbolje opise slika.